

Machine Learning para enfermedades cardiovasculares

Heart Disease Cleveland Dataset

Ignacio Campo Fernández

Director: Ismael Gómez García | TFG Ingeniería Informática | CUNEF Universidad | 2025–2026

El problema

45%

de las muertes en Europa
son cardiovasculares

Fuente: OMS



Diagnóstico complejo

Múltiples variables clínicas simultáneas dificultan su detección a tiempo



Decisiones de alto impacto

Un falso negativo puede ser fatal: el paciente enfermo se va a casa sin tratar



El reto del modelo caja negra

No basta con que el modelo acierte — el médico necesita entender por qué

Dataset y metodología

303

pacientes

Heart Disease Cleveland Dataset (UCI)

13

variables clínicas

Edad, tipo de dolor, ECG, vasos, talasemia...

1

variable objetivo

Enfermedad cardíaca: Sí / No

Metodología

1

Análisis exploratorio
de datos

2

Preproceso
& Split 80/20

3

4 modelos
entrenados

4

Métricas
Accuracy + Recall


5

SHAP
Interpretabilidad

Naive Bayes · Random Forest · Gradient Boosting · Regresión Logística

¿Qué variables importan? Análisis exploratorio

Correlación con enfermedad cardíaca



Decisión de preprocesamiento

fbs y chol eliminadas

$r = 0.03$ y $r = 0.09$
(correlación casi nula con target)

Validación empírica (ej. Reg. Logística, CV=5)


Con fbs/chol: **Acc 0.832 | Recall 0.798**

Sin fbs/chol: **Acc 0.825 | Recall 0.784**

*Diferencia < 0.03 → pérdida marginal.
Modelo más simple e interpretable.*

Resultados de los modelos

Recall en test (métrica clave — minimizar falsos negativos)



Más complejidad ≠ mejor resultado · Naive Bayes supera a Gradient Boosting en este dataset de tamaño moderado

ROC-AUC en test

Random Forest



Reg. Logística



Naive Bayes



Grad. Boosting



Random Forest: mejor capacidad discriminativa global

Interpretabilidad: ¿por qué predice el modelo?



¿Qué son los Shapley Values (SHAP)?

Miden cuánto contribuye cada variable a la predicción de cada paciente. Variables con valor SHAP positivo → empujan hacia 'enfermo'. Variables negativas → empujan hacia 'sano'.



Efecto protector: thalach

Mayor frecuencia cardíaca máxima → SHAP negativo → reduce la probabilidad predicha de enfermedad. Coherente con evidencia clínica: mayor capacidad cardíaca es señal de buena salud.

Variables más determinantes (3 modelos coinciden):

ca

Nº vasos principales afectados

Mayor afectación = más riesgo

cp

Tipo de dolor torácico

Indicador directo de patología cardíaca

thal

Resultado de prueba de talasemia

Detecta el tipo de defecto cardíaco

Conclusiones

01



Sencillo puede superar a complejo

Naive Bayes lidera en recall (0.800) y accuracy (0.852). En datasets pequeños, la complejidad del modelo no garantiza mejores resultados.

02



La métrica importa tanto como el modelo

Accuracy sola puede engañar. Recall y ROC-AUC revelan el comportamiento real en contexto clínico, donde minimizar falsos negativos es prioritario.

03



Predecir y explicar: el valor diferencial

SHAP identifica ca, cp y thal como variables clave de forma consistente en tres modelos distintos. Esta consistencia refuerza que tienen un papel relevante en la predicción, y además es coherente con la interpretación clínica.

Trabajo futuro & Limitaciones

1

Más datos

Combinar Cleveland con otros datasets UCI (Hungría, Suiza) para pasar de 303 a >900 pacientes.

2

Optimización de hiperparámetros

Grid Search para saber cuántos hiperparámetros usar en Gradient Boosting y Random Forest — especialmente útil con más datos.

3

Tratamiento del desbalance

Aplicar SMOTE para generar enfermos artificiales parecidos a los reales

4

Modelos avanzados

XGBoost, LightGBM o redes neuronales en datasets más grandes.