

Machine Learning para enfermedades cardiovasculares sobre el dataset Heart Disease Cleveland

Autor/a:

Ignacio Campo Fernández

Director/a:

Ismael Gómez García

Trabajo Fin de Grado en Ingeniería Informática

2025-2026

Agradecimientos

En primer lugar, quiero agradecer a mi tutor, Ismael Gómez García, por su disponibilidad, sus correcciones y los consejos que me ha dado a lo largo de este trabajo. Su orientación ha sido clave para mejorar tanto el contenido, que en primer lugar carecía de formalidad, como la presentación de esta memoria.

También quiero dar las gracias a mi familia y amigos por el apoyo durante estos años de carrera, especialmente en los momentos más difíciles de los primeros años de la misma.

Por último, agradecer a CUNEF Universidad y a la Escuela Politécnica Superior la formación recibida, que me ha dado las herramientas necesarias para llevar a cabo este proyecto.

Resumen

En este Trabajo de Fin de Grado se desarrolla un sistema de clasificación para la predicción de enfermedad cardiovascular mediante técnicas de aprendizaje automático aplicadas al Heart Disease Cleveland Dataset. Este conjunto de datos está compuesto por 303 pacientes y 14 variables clínicas y demográficas, de las cuales 13 actúan como variables predictoras y una variable objetivo indica la presencia o ausencia de enfermedad cardíaca.

En primer lugar, se realiza un análisis exploratorio de los datos con el objetivo de comprender la estructura del dataset y estudiar la relación entre las variables disponibles. Se genera una matriz de correlación que permite observar las relaciones lineales entre variables, y se evalúa el impacto de eliminar las variables fbs y chol, al presentar una correlación reducida con la variable objetivo.

Posteriormente, el conjunto de datos se divide en subconjuntos de entrenamiento y prueba (80 % y 20 %), incorporando validación cruzada para obtener una estimación más completa del rendimiento. Se entrenan y comparan cuatro modelos de clasificación: Naive Bayes, Random Forest, Gradient Boosting y Regresión Logística.

El rendimiento de los modelos se evalúa mediante accuracy, recall, precision, F1-score y ROC-AUC, prestando especial atención al recall, pues se le otorga especial importancia dado el contexto clínico del problema, donde la prioridad no es solo acertar sino minimizar los falsos negativos.

Como aportación diferencial respecto a trabajos previos sobre el mismo dataset, se aplica un análisis de interpretabilidad mediante Shapley Values (SHAP), que permite identificar qué variables clínicas son más relevantes para cada modelo y en qué dirección influyen sobre la predicción. Este análisis revela que las variables ca, cp y thal son sistemáticamente las más determinantes en los tres modelos analizados, lo cual es coherente con la evidencia clínica disponible.

Abstract

This Final Degree Project develops a classification system for cardiovascular disease prediction using machine learning techniques applied to the Heart Disease Cleveland Dataset. This dataset consists of 303 patients and 14 clinical and demographic variables, of which 13 are used as predictors and one target variable indicates the presence or absence of heart disease.

An exploratory data analysis is first carried out to understand the structure of the dataset and examine the relationships between variables. A correlation matrix is generated to study linear relationships, and the impact of removing the variables fbs and chol is evaluated, as they show low correlation with the target variable.

The dataset is then divided into training and test subsets (80 % and 20 %), incorporating cross-validation to obtain a more solid estimate of model performance. Four classification models are trained and compared: Naive Bayes, Random Forest, Gradient Boosting, and Logistic Regression.

Model performance is evaluated using accuracy, recall, precision, F1-score, and ROC-AUC, with special attention to recall given the clinical context of the problem, where it is not only about reducing mistakes but mainly about minimizing false negatives.

As the main differentiating contribution with respect to previous works on this dataset, an interpretability analysis is carried out using Shapley Values (SHAP). This analysis identifies which clinical variables are most relevant for each model and in which direction they influence the prediction. Results show that the variables ca, cp, and thal are consistently the most important across the three models analyzed, a finding that is coherent with available clinical evidence.

Índice general

Resumen	3
Abstract	4
1 Introducción	6
1.1 Objetivo y justificación del trabajo	7
1.2 Marco teórico: algoritmos y métricas de validación	7
1.2.1 Métricas de evaluación	8
1.2.2 Naive Bayes	8
1.2.3 Random Forest	9
1.2.4 Gradient Boosting	9
1.2.5 Regresión Logística	9
1.3 Estado de la cuestión: trabajos previos sobre el mismo dataset	10
2 Descripción del dataset	12
2.1 Descripción y explicación del dataset	12
2.2 Tipos de variables	13
2.3 Interpretación general del dataset	14
3 Análisis exploratorio de datos	15
4 Preparación de los datos	18
5 Resultados y evaluación de modelos	20
5.1 Métricas de evaluación	20
5.2 Resultados por modelo	20
5.2.1 Naive Bayes	21
5.2.2 Random Forest	21
5.2.3 Gradient Boosting	21
5.2.4 Regresión Logística	21
5.3 Matrices de confusión	21
5.3.1 Naive Bayes	22
5.3.2 Random Forest	22
5.3.3 Gradient Boosting	23
5.3.4 Regresión Logística	24
5.4 Análisis de interpretabilidad: Shapley Values	24
5.4.1 Qué son los Shapley Values	24
5.4.2 Implementación	25
5.4.3 Resultados: importancia media SHAP	25
5.4.4 Gráficos SHAP coloreados por clase predicha	26
5.4.5 Coeficientes de la Regresión Logística	26
5.4.6 Comparativa SHAP: predicciones disease vs no disease	27
5.4.7 Comparativa SHAP vs coeficientes	27
5.5 Comparación y discusión de resultados	28
5.6 Conclusiones y trabajo futuro	29
Bibliografía	32
Anexo: Resultados adicionales	33

1 Introducción

Las enfermedades cardiovasculares continúan siendo uno de los principales problemas de salud a nivel mundial [1]. Este tipo de patologías representa una de las causas más frecuentes de mortalidad en muchos países desarrollados y también en los que están en desarrollo. La cardiopatía coronaria, el infarto de miocardio y otras alteraciones relacionadas con el funcionamiento del sistema cardiovascular son muy comunes. La elevada incidencia de estas enfermedades, además del impacto que generan tanto en la calidad de vida de los pacientes como en los sistemas sanitarios, ha hecho que exista una gran preocupación por mejorar las estrategias de prevención, diagnóstico y tratamiento.

En Europa, las enfermedades cardiovasculares representan la principal causa de muerte, siendo responsables de aproximadamente el 45 % de todos los fallecimientos [1]. Según la Organización Mundial de la Salud, cada año mueren más de 17 millones de personas en el mundo a causa de enfermedades cardiovasculares, lo que supone un problema de salud pública de primer orden [1].

Muchas veces las enfermedades cardiovasculares se desarrollan a partir de situaciones en las que interactúan múltiples factores de riesgo. Algunos de estos factores están relacionados con características demográficas, como la edad o el sexo, mientras que otros dependen de condiciones clínicas específicas, como la hipertensión, el colesterol elevado o determinados hábitos de vida [2]. Esta combinación de variables hace que el diagnóstico a tiempo y la evaluación del riesgo cardiovascular sean de gran dificultad, ya que es necesario analizar varios indicadores clínicos de forma simultánea.

En las últimas décadas, el desarrollo de nuevas tecnologías y el aumento de la capacidad de almacenamiento de datos han permitido que el ámbito sanitario disponga de grandes volúmenes de información clínica. Esta disponibilidad de datos ha favorecido la aparición de nuevas líneas de investigación centradas en el análisis de datos médicos mediante herramientas computacionales. En este contexto, el uso de técnicas de aprendizaje automático (*machine learning*) ha experimentado un crecimiento notable [3] porque ofrece la posibilidad de identificar patrones complejos en los datos y construir modelos capaces de realizar predicciones sobre nuevos casos.

El aprendizaje automático se puede definir como una rama de la inteligencia artificial [4] que se centra en el desarrollo de algoritmos capaces de aprender a partir de datos. En lugar de basarse únicamente en reglas programadas, estos algoritmos emplean ejemplos previamente observados para detectar relaciones entre variables y generar modelos predictivos. Una vez entrenado el modelo, este puede utilizarse para realizar predicciones o clasificaciones cuando se presentan nuevos datos.

En el ámbito de la medicina, las aplicaciones del aprendizaje automático son muy diversas [5]. Estas técnicas se utilizan, por ejemplo, en la detección automática de enfermedades a partir de imágenes médicas, en el análisis de historiales clínicos electrónicos o en la predicción del riesgo de determinadas patologías. La principal ventaja de estos métodos es su capacidad para analizar grandes cantidades de información y detectar relaciones que pueden resultar difíciles de identificar mediante métodos tradicionales de análisis estadístico.

A pesar de su potencial, el uso de técnicas de aprendizaje automático en el ámbito sanitario también presenta ciertas dificultades. En aplicaciones clínicas, no basta con que un modelo realice predicciones precisas, sino que también es necesario que los profesionales sanitarios puedan comprender de forma razonable cómo se obtiene dicha predicción. Esta necesidad de transparencia es especialmente relevante en decisiones de alto impacto, donde los modelos pueden comportarse como cajas negras si no ofrecen una explicación interpretable de sus resultados [6, 7]. Un modelo que dice simplemente que un paciente tiene un 85 % de probabilidad de estar enfermo es mucho menos útil en la práctica clínica que uno que además indica qué variables han llevado a esa conclusión. Por este motivo, la interpretabilidad constituye uno de los ejes centrales de este trabajo.

1.1 Objetivo y justificación del trabajo

En este trabajo se desarrolla un sistema de predicción de enfermedad cardiovascular utilizando el conjunto de datos conocido como *Heart Disease Cleveland Dataset* [8]. El objetivo principal no es únicamente comparar el rendimiento de distintos algoritmos de aprendizaje automático, sino también analizar la interpretabilidad de sus predicciones mediante el uso de Shapley Values (SHAP) [9]. Este análisis permite identificar qué variables clínicas son más relevantes para cada modelo y en qué dirección influyen sobre la predicción, aportando una perspectiva que los trabajos previos sobre este dataset no han abordado.

En este trabajo se han seleccionado cuatro modelos representativos de diferentes enfoques: Naive Bayes [10], Regresión Logística [11], Random Forest [12] y Gradient Boosting [13], cuya descripción detallada se recoge en la Sección 1.2.

Además de este capítulo introductorio, el contenido de esta memoria se organiza de la siguiente forma:

- **Capítulo 2. Descripción del dataset:** se presentan los datos utilizados en el trabajo, incluyendo la descripción de las variables, su interpretación general y su relación con el problema de estudio.
- **Capítulo 3. Análisis exploratorio de datos:** se realiza un estudio inicial del dataset con el objetivo de entender su estructura, detectar patrones y analizar las relaciones entre variables.
- **Capítulo 4. Preparación de los datos:** se describen los pasos de preprocesamiento realizados sobre los datos, incluyendo limpieza, transformación y adecuación para el entrenamiento de los modelos.
- **Capítulo 5. Resultados y evaluación de modelos:** se recogen los resultados obtenidos, el análisis de interpretabilidad mediante SHAP, las principales conclusiones del estudio y se proponen posibles líneas de mejora o investigación futura.

1.2 Marco teórico: algoritmos y métricas de validación

En esta sección se describen los fundamentos teóricos necesarios para comprender el trabajo: las métricas utilizadas para evaluar el rendimiento de los modelos y los algoritmos de aprendizaje automático empleados.

1.2.1 Métricas de evaluación

Para evaluar el rendimiento de los modelos de clasificación se utilizan diversas métricas que permiten analizar su comportamiento desde distintas perspectivas.

El **accuracy** mide la proporción de predicciones correctas sobre el total de observaciones:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.1)$$

El **recall** o sensibilidad mide la capacidad del modelo para identificar correctamente los casos positivos, es decir, los pacientes con enfermedad:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.2)$$

La **precision** indica qué proporción de las predicciones positivas son realmente correctas:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1.3)$$

El **F1-score** combina precision y recall en una única métrica mediante su media armónica:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (1.4)$$

Por último, el **ROC-AUC** mide la capacidad del modelo para separar correctamente a los pacientes sanos de los pacientes enfermos. Es decir, evalúa si el modelo asigna puntuaciones más altas a los pacientes con enfermedad que a los pacientes sin enfermedad. Un valor cercano a 1 indica que el modelo distingue muy bien entre ambas clases, mientras que un valor cercano a 0.5 indicaría que el modelo apenas distingue mejor que una clasificación al azar.

En un contexto clínico, el recall es especialmente relevante, ya que minimizar los falsos negativos (pacientes enfermos clasificados como sanos) es fundamental para evitar errores diagnósticos con consecuencias graves.

1.2.2 Naive Bayes

Naive Bayes es un algoritmo de clasificación probabilístico basado en el teorema de Bayes [10]. La idea es sencilla: dado un paciente con unas determinadas variables clínicas, el modelo calcula la probabilidad de que pertenezca a cada clase (enfermo o sano) y lo asigna a la más probable.

La fórmula central del algoritmo es:

$$P(\text{clase} \mid \text{datos}) \propto P(\text{clase}) \cdot P(\text{datos} \mid \text{clase}) \quad (1.5)$$

Es decir, la probabilidad de que un paciente sea enfermo depende de dos cosas: cuántos enfermos hay en los datos de entrenamiento (probabilidad a priori), y cuánto se parecen sus valores clínicos a los de los pacientes enfermos que el modelo ya conoce (probabilidad condicional).

La hipótesis que da nombre al algoritmo es que las variables son independientes entre sí, es decir, que cada una aporta información por separado. En datos clínicos esto no siempre se cumple, pero en la práctica el modelo funciona bien precisamente porque simplifica mucho el problema [10]. En la variante Gaussiana (GaussianNB), utilizada en este trabajo, se asume que las variables continuas siguen una distribución normal dentro de cada clase.

Entre sus ventajas destacan su rapidez, su sencillez y su buen comportamiento con datasets de tamaño moderado. Ha sido ampliamente utilizado en clasificación médica por estas razones [10].

1.2.3 Random Forest

Random Forest es un método ensemble basado en árboles de decisión, propuesto por Breiman [12]. La motivación es sencilla: un único árbol de decisión tiende a sobreajustarse a los datos de entrenamiento, pero si se combinan muchos árboles distintos, sus errores individuales tienden a compensarse y el resultado global es más fiable.

Para conseguir que los árboles sean diversos, el algoritmo entrena cada uno sobre una muestra distinta de los datos y considerando solo un subconjunto aleatorio de variables en cada división. La predicción final se obtiene por votación mayoritaria:

$$\hat{y} = \text{clase más votada entre los } T \text{ árboles} \quad (1.6)$$

Si la mayoría de los árboles predicen que un paciente tiene enfermedad, esa será la predicción final del modelo. Este mecanismo de votación es lo que hace a Random Forest robusto frente al sobreajuste [12].

Entre sus ventajas destacan que funciona correctamente con variables mixtas, no requiere estandarización y es robusto frente a valores atípicos. Su principal limitación es la interpretabilidad: al combinar cientos de árboles, es difícil entender por qué el modelo toma una decisión concreta, lo que hace especialmente relevante el análisis SHAP aplicado en este trabajo.

1.2.4 Gradient Boosting

Gradient Boosting es otro método ensemble basado en árboles, introducido por Friedman [13]. La diferencia respecto a Random Forest es que aquí los árboles se construyen de forma secuencial: cada nuevo árbol se entrena para corregir los errores que cometió el modelo anterior. El modelo va mejorando poco a poco en cada iteración, aprendiendo de sus propios fallos.

El modelo final es la suma de todos los árboles entrenados:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}) \quad (1.7)$$

donde h_m es el árbol añadido en el paso m y η es la tasa de aprendizaje, que controla cuánto contribuye cada árbol al resultado final.

Gradient Boosting tiene una gran capacidad para capturar relaciones complejas entre variables [13]. Su principal inconveniente es que es más sensible a la configuración de parámetros que Random Forest, y puede sobreajustarse si no se ajusta con cuidado.

1.2.5 Regresión Logística

La Regresión Logística es uno de los modelos más utilizados en el ámbito médico y estadístico [11]. A pesar de su nombre, no es un modelo de regresión sino de clasificación: estima la probabilidad de que un paciente tenga enfermedad transformando una combinación lineal de sus variables en un valor entre 0 y 1 mediante la función sigmoide:

$$P(\text{enfermedad}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (1.8)$$

Cada β_i es el peso que el modelo asigna a la variable i : si es positivo, esa variable aumenta la probabilidad de enfermedad; si es negativo, la reduce. La clase predicha se obtiene comparando la probabilidad estimada con un umbral de 0.5.

Su mayor ventaja es la interpretabilidad: se puede ver directamente qué variables el modelo considera más relevantes y en qué sentido influyen, lo que resulta muy útil en un contexto clínico [11]. Su limitación principal es que asume relaciones lineales entre las variables y la probabilidad de enfermedad, lo que puede penalizar su rendimiento cuando las relaciones son más complejas.

1.3 Estado de la cuestión: trabajos previos sobre el mismo dataset

El *Heart Disease Cleveland Dataset* ha sido ampliamente utilizado en la literatura científica, lo que permite situar este trabajo en un contexto más amplio y comparar la metodología y los resultados con los de estudios similares. Es importante conocer estos trabajos desde el inicio, ya que condicionan directamente el valor diferencial que este trabajo pretende aportar.

Perumal y Kaladevi [14] evaluaron tres clasificadores sobre el mismo dataset: Regresión Logística, SVM y KNN, aplicando previamente PCA para reducir la dimensionalidad. La Regresión Logística fue el modelo con mejor rendimiento, alcanzando un accuracy del 87 % y un recall del 85 %.

Shrestha [15] realizó una comparativa más amplia utilizando exactamente la misma división de datos (80 % entrenamiento, 20 % prueba), lo que hace sus resultados directamente comparables con los de este trabajo. Evaluó Regresión Logística, Random Forest, Gradient Boosting, XGBoost y redes LSTM. Los mejores resultados los obtuvo la Regresión Logística con un 89 % de accuracy y un recall del 91 %.

La Tabla 1.1 resume los resultados de estos trabajos previos, para facilitar la comparación con los obtenidos en el presente trabajo, que se presentan en detalle en el Capítulo 5.

Trabajo	Modelo	Accuracy	Recall
Perumal y Kaladevi [14]	Regresión Logística	0.87	0.85
Perumal y Kaladevi [14]	SVM	0.85	0.82
Perumal y Kaladevi [14]	KNN	0.69	—
Shrestha [15]	Regresión Logística	0.89	0.91
Shrestha [15]	Random Forest	0.87	0.84
Shrestha [15]	Gradient Boosting	0.85	0.84
Shrestha [15]	XGBoost	0.85	0.84
Shrestha [15]	LSTM	0.85	0.78

Cuadro 1.1: Resultados de trabajos previos sobre el mismo dataset

Como se puede observar, los trabajos previos reportan accuracies de entre el 69 % y el 89 %. Sin embargo, ninguno de estos trabajos aborda la pregunta de *por qué* los modelos toman sus decisiones. Este es precisamente el valor diferencial del presente trabajo: además de entrenar y comparar los modelos, se aplica un análisis de interpretabilidad mediante Shapley Values (SHAP) [9] que permite identificar qué variables clínicas son más relevantes para cada modelo y en qué dirección influyen sobre la predicción. Esta perspectiva resulta especialmente útil en un contexto clínico, donde entender el razonamiento detrás de un diagnóstico es tan importante como la precisión del modelo.

Con este análisis se pretende no solo desarrollar un proyecto académico, sino explorar el potencial de estas técnicas para apoyar el análisis de datos médicos y contribuir al desarrollo de herramientas que, en un futuro, faciliten la identificación temprana de pacientes con riesgo cardiovascular.

2 Descripción del dataset

2.1 Descripción y explicación del dataset

El conjunto de datos utilizado en este trabajo es el conocido como *Heart Disease Cleveland Dataset*, disponible públicamente en el repositorio UCI Machine Learning Repository [8]. Se trata de uno de los datasets más utilizados en la literatura científica para el desarrollo y evaluación de modelos de predicción de enfermedad cardiovascular [16, 17]. Entre los trabajos que lo han empleado destacan estudios que aplican algoritmos como Random Forest, Regresión Logística o Gradient Boosting, obteniendo accuracies de entre el 69 % y el 89 % según la metodología utilizada. El hecho de que sea un dataset público y ampliamente conocido facilita la comparación de resultados con otros trabajos, lo que constituye una de sus principales ventajas desde el punto de vista académico.

El dataset contiene 303 observaciones, donde cada una corresponde a un paciente distinto. Cada paciente está descrito mediante 14 variables clínicas y demográficas, de las cuales 13 actúan como variables predictoras y una es la variable objetivo (target), que indica si el paciente tiene enfermedad cardíaca (valor 1) o no (valor 0). Esto permite formular el problema como una tarea de clasificación binaria.

Aunque no es un dataset de grandes dimensiones, resulta adecuado para este tipo de análisis porque contiene información clínica relevante y permite aplicar distintos modelos de aprendizaje automático sin necesidad de recursos computacionales elevados. Además, trabajar con datos reales de pacientes garantiza que las relaciones entre variables tienen un fundamento clínico real, lo que da mayor validez a los resultados.

Las variables predictoras recogen distintos aspectos de la salud cardiovascular del paciente. Algunas son demográficas, como la edad (**age**) o el sexo (**sex**). Otras recogen parámetros clínicos como la presión arterial en reposo (**trestbps**) o el nivel de colesterol (**chol**). También hay variables relacionadas con pruebas médicas concretas, como el electrocardiograma en reposo (**restecg**), la frecuencia cardíaca máxima alcanzada (**thalach**) o la angina inducida por ejercicio (**exang**). Entre las más relevantes se encuentran **cp** (tipo de dolor torácico), **oldpeak** (depresión del segmento ST durante el ejercicio), **ca** (número de vasos principales afectados) y **thal** (resultado de una prueba relacionada con la talasemia).

La siguiente tabla resume cada variable, su tipo y su relevancia clínica esperada:

La variable objetivo (**target**) es la que se pretende predecir con los modelos. El dataset contiene 164 pacientes sin enfermedad ($\text{target} = 0$) y 139 con enfermedad ($\text{target} = 1$), lo que supone un ligero desbalance entre clases. Este aspecto es importante porque en situaciones de desbalance el accuracy puede resultar engañoso, por lo que se han utilizado también otras métricas como el recall, el F1-score y el ROC-AUC.

Variable	Tipo	Descripción y relevancia
age	Numérica	Edad del paciente. Mayor edad implica mayor riesgo cardiovascular.
sex	Categórica	Sexo (1 = hombre, 0 = mujer). El riesgo varía según el sexo.
cp	Categórica	Tipo de dolor torácico. Indicador directo de posible patología cardíaca.
trestbps	Numérica	Presión arterial en reposo. La hipertensión es factor de riesgo clave.
chol	Numérica	Nivel de colesterol sérico. El colesterol elevado aumenta el riesgo CV.
fbs	Categórica	Glucemia en ayunas > 120 mg/dl. Relacionada con diabetes y riesgo CV.
restecg	Categórica	Resultado del electrocardiograma en reposo. Detecta anomalías cardíacas.
thalach	Numérica	Frecuencia cardíaca máxima. Valores bajos pueden indicar problemas.
exang	Categórica	Angina inducida por ejercicio. Síntoma relevante de enfermedad coronaria.
oldpeak	Numérica	Depresión del segmento ST. Indica isquemia miocárdica.
slope	Categórica	Pendiente del segmento ST. Relacionada con la gravedad de la isquemia.
ca	Numérica	Número de vasos principales coloreados. Mayor número indica mayor afectación.
thal	Categórica	Resultado de prueba de talasemia. Indica el tipo de defecto cardíaco.
target	Binaria	Variable objetivo: 1 = enfermedad cardíaca, 0 = sin enfermedad.

Cuadro 2.1: Descripción de las variables del dataset Heart Disease Cleveland

2.2 Tipos de variables

El dataset combina variables numéricas y categóricas, lo cual es habitual en datos clínicos. Por un lado, variables numéricas continuas como la edad, la presión arterial, el colesterol o la frecuencia cardíaca máxima. Por otro, variables categóricas como el tipo de dolor torácico, el resultado del electrocardiograma o la variable thal.

Esta combinación plantea un reto concreto: las variables numéricas tienen rangos muy distintos. Por ejemplo, la edad oscila entre 29 y 77 años, mientras que el colesterol puede superar los 500 mg/dl. Esta diferencia de escala puede perjudicar a modelos sensibles a la magnitud de las variables, como la Regresión Logística. Para resolverlo, se aplica una estandarización mediante **StandardScaler**, que transforma cada variable para que tenga media cero y desviación típica uno. Modelos como Random Forest o Gradient Boosting no necesitan este paso porque son robustos frente a diferencias de escala.

2.3 Interpretación general del dataset

El dataset recoge distintas dimensiones del estado de salud del paciente: información demográfica, síntomas, resultados de pruebas médicas y variables fisiológicas. Esto es importante porque en situaciones clínicas reales el diagnóstico no depende de una sola variable, sino de la combinación de varias. Por ejemplo, un colesterol alto por sí solo no indica necesariamente enfermedad, pero combinado con la edad, el tipo de dolor torácico o la respuesta al ejercicio puede ser muy informativo. La capacidad predictiva real de estas variables se evaluará al validar los modelos entrenados.

3 Análisis exploratorio de datos

Antes de proceder al entrenamiento de los modelos, se llevó a cabo un análisis exploratorio de los datos con el objetivo de comprender la estructura del dataset, identificar posibles patrones y examinar las relaciones entre variables que pudieran resultar relevantes para la predicción de enfermedad cardiovascular.

En primer lugar, tras cargar el dataset, se procedió a mezclar aleatoriamente las observaciones mediante una semilla fija (`random_state = 42`), con el fin de garantizar la reproducibilidad del proceso y evitar posibles sesgos derivados de un eventual ordenamiento previo de los datos.

Estadística descriptiva

La Tabla 3.1 resume las principales estadísticas descriptivas de las variables numéricas del dataset, incluyendo la media, desviación típica, valor mínimo y máximo para el conjunto completo de 303 pacientes.

Variable	Media	Desv. típica	Mín.	Máx.
age	54.44	9.04	29	77
trestbps	131.69	17.60	94	200
chol	246.69	51.78	126	564
thalach	149.61	22.88	71	202
oldpeak	1.04	1.16	0.0	6.2
ca	0.66	0.93	0	3
thal	1.83	0.96	1	3

Cuadro 3.1: Estadísticas descriptivas de las variables numéricas

En cuanto a la distribución de la variable objetivo, el dataset contiene 164 pacientes sin enfermedad cardíaca (`target = 0`) y 139 con enfermedad (`target = 1`), lo que supone un ligero desbalance que se ha tenido en cuenta en la elección de métricas de evaluación. En cuanto al sexo, el 68 % de los pacientes son hombres (`sex = 1`).

Análisis comparativo por grupo

Con el objetivo de evaluar si las variables presentan diferencias entre los pacientes con y sin enfermedad cardiovascular, se realizó un análisis comparativo entre ambos grupos. La Tabla 3.2 muestra las medias de las variables desglosadas por valor de la variable objetivo.

De esta comparativa se desprenden varias observaciones relevantes. Los pacientes con enfermedad presentan una edad media superior (56.63 vs 52.59 años) y una frecuencia

Variable	Sin enfermedad (target=0)	Con enfermedad (target=1)
age	52.59	56.63
sex	0.56	0.82
cp	1.79	2.59
trestbps	129.25	134.57
chol	242.64	251.47
thalach	158.38	139.26
exang	0.14	0.55
oldpeak	0.59	1.57
slope	0.41	0.83
ca	0.27	1.13
thal	1.38	2.37

Cuadro 3.2: Media de variables por grupo (target)

cardíaca máxima notablemente más baja (139.26 vs 158.38 lpm). La depresión del segmento ST (**oldpeak**) es considerablemente mayor en el grupo enfermo (1.57 vs 0.59), al igual que el número de vasos afectados (**ca**: 1.13 vs 0.27) y el valor de **thal** (2.37 vs 1.38). La presencia de angina inducida por ejercicio (**exang**) es también mucho más frecuente en pacientes enfermos (0.55 vs 0.14). Por el contrario, **chol** (251.47 vs 242.64) y **trestbps** (134.57 vs 129.25) muestran diferencias mucho más pequeñas entre grupos, lo que es coherente con su baja correlación con la variable objetivo.

Análisis de correlación

Con el propósito de examinar las relaciones lineales entre variables, se generó una matriz de correlación visualizada mediante un mapa de calor (*heatmap*), que se muestra en la Figura 3.1.

Del análisis de la correlación con la variable objetivo (**target**) se extraen varias conclusiones relevantes. Las variables que presentan una asociación más fuerte con la presencia de enfermedad cardíaca son **thal** ($r = 0,52$), **ca** ($r = 0,46$), **exang** ($r = 0,43$), **oldpeak** ($r = 0,42$) y **cp** ($r = 0,41$). Por su parte, **thalach** muestra una correlación negativa considerable ($r = -0,42$), lo que indica que una mayor frecuencia cardíaca máxima se asocia con que las probabilidades de estar enfermo sean menores. Variables como **slope** ($r = 0,34$) y **sex** ($r = 0,28$) presentan una asociación moderada, mientras que **age** muestra una correlación positiva débil ($r = 0,22$).

En el extremo opuesto, las variables **fbs** ($r = 0,03$) y **chol** ($r = 0,09$) presentan correlaciones muy próximas a cero con la variable objetivo, lo que sugiere que, desde un punto de vista lineal, su contribución individual a la predicción es limitada en este dataset. A partir de esta observación, se evaluó el impacto de su eliminación en el rendimiento de los modelos, decisión que se analiza con mayor detalle en el capítulo siguiente.

Más adelante, cabe destacar la existencia de correlaciones relevantes entre algunas variables predictoras. En particular, **oldpeak** y **slope** presentan una correlación de $r = 0,58$, lo que podría indicar cierta redundancia de información entre ambas. Este tipo de multicolinealidad puede afectar especialmente al rendimiento de modelos como la Regresión Logística, aunque resulta menos problemático en modelos basados en árboles como Random Forest o Gradient Boosting.




Figura 3.1: Matriz de correlación entre las variables del dataset

Consideraciones sobre la escala de las variables

El análisis exploratorio también mostró que las variables numéricas presentan rangos de valores considerablemente distintos entre sí. Esta escala tan distinta puede perjudicar el rendimiento de modelos sensibles a la magnitud de las variables, como la Regresión Logística. Por este motivo, en dicho modelo se aplicó una estandarización mediante **StandardScaler**, que transforma cada variable para que presente media cero y desviación típica uno. Los modelos basados en árboles, como Random Forest o Gradient Boosting, no requieren este preprocesamiento al no verse tan afectados por las diferencias de escala.

En conjunto, esta fase de análisis exploratorio permitió identificar las variables con mayor capacidad discriminante, detectar posibles redundancias entre predictores y establecer las decisiones de preprocesamiento necesarias para las etapas posteriores del análisis.

4 Preparación de los datos

Una vez realizado el análisis exploratorio, el siguiente paso consiste en preparar los datos para su uso en los modelos de aprendizaje automático. En este capítulo se describen las decisiones tomadas en dos fases diferenciadas: la selección y transformación de variables (*feature selection* y preprocesamiento), que constituyen un paso previo al entrenamiento, y la estrategia de validación adoptada para evaluar el rendimiento de los modelos de forma fiable.

Selección y preprocesamiento de variables

En primer lugar, se procedió a mezclar aleatoriamente las observaciones del dataset mediante una semilla fija (`random_state = 42`), con el fin de garantizar la reproducibilidad del proceso y evitar posibles sesgos derivados de unos datos previamente ordenados. Este paso es especialmente importante cuando posteriormente se realiza la división en conjuntos de entrenamiento y prueba, ya que garantiza que ambos subconjuntos sean representativos del conjunto total.

A continuación, se decidió eliminar dos variables del dataset: `fb` y `chol`. Esta decisión se basó en el análisis de correlación realizado en el capítulo anterior, donde se observó que ambas variables presentaban una correlación muy baja con la variable objetivo ($r = 0,03$ y $r = 0,09$ respectivamente), además de no mostrar diferencias significativas entre los grupos de pacientes sanos y enfermos. El objetivo de esta eliminación es simplificar el modelo y reducir posibles fuentes de ruido que puedan afectar negativamente al proceso de aprendizaje.

No obstante, es importante destacar que esta decisión no se toma de forma arbitraria. Variables con baja correlación lineal individual pueden aportar información útil en combinación con otras, por lo que su impacto se evalúa posteriormente comparando el rendimiento de los modelos con y sin estas variables.

Con el fin de validar empíricamente esta decisión, se evaluó el rendimiento de los cuatro modelos mediante validación cruzada ($cv=5$) sobre el dataset completo y sobre el dataset reducido. Los resultados se recogen en la Tabla 4.1.

Modelo	Variables	Accuracy (CV)	Recall (CV)
Naive Bayes	Con fbs/chol	0.838	0.812
Naive Bayes	Sin fbs/chol	0.838	0.812
Random Forest	Con fbs/chol	0.828	0.762
Random Forest	Sin fbs/chol	0.815	0.748
Gradient Boosting	Con fbs/chol	0.831	0.798
Gradient Boosting	Sin fbs/chol	0.818	0.769
Regresión Logística	Con fbs/chol	0.832	0.798
Regresión Logística	Sin fbs/chol	0.825	0.784

Cuadro 4.1: Comparativa de rendimiento con y sin las variables **fbs** y **chol**

Los resultados muestran que la eliminación de **fbs** y **chol** no produce una mejora en el rendimiento de los modelos; en la mayoría de casos provoca una ligera reducción tanto en accuracy como en recall. Sin embargo, las diferencias son pequeñas (inferiores a 0.03 en todos los casos), lo que confirma que la contribución de estas variables al modelo es marginal. La decisión de eliminarlas se mantiene por la siguiente razón: reducir el número de variables sin pérdida significativa de rendimiento permite que el modelo sea simplificado y lo hace más interpretable.

Estrategia de validación

Una vez preparado el conjunto de datos, se definió la estrategia para evaluar el rendimiento de los modelos. En este trabajo se han combinado dos enfoques complementarios: la división train-test y la validación cruzada.

En primer lugar, se dividió el dataset en dos subconjuntos: un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %), lo que corresponde a 242 y 61 observaciones respectivamente. El conjunto de entrenamiento se utiliza para ajustar los parámetros de los modelos, mientras que el conjunto de prueba permite evaluar su capacidad de generalización sobre datos no vistos durante el entrenamiento.

Adicionalmente, se aplicó una validación cruzada de 5 particiones ($cv = 5$) sobre el conjunto de entrenamiento. Este enfoque divide los datos en 5 subconjuntos y repite el proceso de entrenamiento y evaluación 5 veces, usando cada vez una partición distinta como conjunto de validación. De esta forma se obtiene una estimación más robusta del rendimiento del modelo, reduciendo la dependencia de una única partición de los datos y minimizando el riesgo de que los resultados sean fruto del azar en la división.

En conjunto, estas decisiones de preprocesamiento y validación constituyen la base sobre la que se entrenan y evalúan los modelos descritos en la sección 1.2.

5 Resultados y evaluación de modelos

5.1 Métricas de evaluación

Para evaluar el rendimiento de los modelos se han utilizado las métricas descritas en el Capítulo 1: accuracy, recall, precision, F1-score y ROC-AUC. Dado que el dataset presenta un ligero desbalance entre clases (164 pacientes sanos frente a 139 enfermos), el accuracy por sí solo puede resultar engañoso, por lo que se ha prestado especial atención al recall y al ROC-AUC, que ofrecen una visión más completa del rendimiento en este tipo de problemas.

5.2 Resultados por modelo

Los modelos se han evaluado mediante dos enfoques complementarios: validación cruzada de 5 particiones ($cv=5$) sobre el conjunto de entrenamiento, y evaluación final sobre el conjunto de prueba (train-test split 80/20).

La Tabla 5.1 muestra los resultados de la validación cruzada, que proporcionan una estimación más robusta del rendimiento al reducir la dependencia de una única partición de los datos.

Modelo	Accuracy	Recall	F1	ROC-AUC
Naive Bayes	0.838	0.812	0.821	0.898
Random Forest	0.815	0.748	0.786	0.897
Gradient Boosting	0.818	0.769	0.793	0.879
Regresión Logística	0.825	0.784	0.802	0.903

Cuadro 5.1: Resultados de validación cruzada ($cv=5$) — métricas completas

La validación cruzada confirma que Naive Bayes es el modelo más consistente, liderando en accuracy y recall. Destaca también la Regresión Logística, que obtiene el ROC-AUC más alto (0.903) en validación cruzada, lo que indica una buena capacidad discriminativa global. Estos resultados son coherentes con los obtenidos sobre el conjunto de prueba, lo que sugiere que los modelos generalizan bien y que los resultados no dependen de una partición concreta de los datos.

La Tabla 5.2 muestra los resultados completos obtenidos sobre el conjunto de prueba, incluyendo todas las métricas de evaluación.

Modelo	Accuracy	Recall	Precision	F1-score	ROC-AUC
Naive Bayes	0.852	0.800	0.833	0.816	0.890
Random Forest	0.820	0.720	0.818	0.766	0.900
Gradient Boosting	0.803	0.760	0.760	0.760	0.863
Regresión Logística	0.836	0.760	0.826	0.792	0.897

Cuadro 5.2: Resultados sobre el conjunto de prueba (train-test split 80/20)

5.2.1 Naive Bayes

Naive Bayes ha obtenido los mejores resultados en términos de accuracy (0.852) y recall (0.800), lo que indica que es el modelo que mejor detecta los casos positivos, es decir, pacientes con enfermedad cardiovascular. Presenta además un F1-score de 0.816, lo que refleja un buen equilibrio entre precision y recall. Estos resultados son llamativos dado que se trata del modelo más sencillo de los cuatro, y sugieren que las variables del dataset tienen una estructura probabilística que favorece este tipo de enfoque.

5.2.2 Random Forest

Random Forest ha obtenido un accuracy de 0.820 y un recall de 0.720. Destaca especialmente su ROC-AUC de 0.900, el más alto entre los cuatro modelos, lo que indica una excelente capacidad para distinguir entre pacientes sanos y enfermos a distintos umbrales de decisión. Aunque no supera a Naive Bayes en recall, ofrece mayor estabilidad y capacidad de generalización.

5.2.3 Gradient Boosting

Gradient Boosting ha sido el modelo con rendimiento más bajo en este caso, con un accuracy de 0.803 y un F1-score de 0.760. Aunque este tipo de modelos suele destacar en problemas más complejos, en este dataset concreto no ha conseguido superar al resto. Esto puede deberse al tamaño limitado del dataset (303 observaciones), que no permite a Gradient Boosting explotar todo su potencial, o a que los parámetros por defecto no son los óptimos para este problema.

5.2.4 Regresión Logística

La Regresión Logística ha mostrado un accuracy de 0.836 y un recall de 0.760, con un ROC-AUC de 0.897. A pesar de ser un modelo lineal y más sencillo, ha conseguido resultados muy competitivos frente a los modelos ensemble, lo que refuerza su idoneidad para este tipo de problemas médicos. Además, su interpretabilidad la convierte en una opción especialmente interesante en contextos clínicos, donde entender la decisión del modelo es tan importante como su precisión.

5.3 Matrices de confusión

Las matrices de confusión permiten analizar en detalle los aciertos y errores de cada modelo, diferenciando entre verdaderos positivos (TP), verdaderos negativos (TN), falsos positivos (FP) y falsos negativos (FN). En un contexto clínico, los falsos negativos son especialmente relevantes, ya que representan pacientes enfermos clasificados como sanos.

5.3.1 Naive Bayes




Figura 5.1: Matriz de confusión — Naive Bayes

Naive Bayes clasifica correctamente 32 pacientes sanos (TN) y 20 enfermos (TP), cometiendo 4 falsos positivos y únicamente 5 falsos negativos. Es el modelo con menor número de falsos negativos de los cuatro analizados, lo que lo convierte en el más adecuado desde una perspectiva clínica. Cada falso negativo representa un paciente enfermo al que el modelo clasifica como sano, por lo que minimizar este tipo de error es prioritario en este contexto.

5.3.2 Random Forest




Figura 5.2: Matriz de confusión — Random Forest

Random Forest clasifica correctamente 32 pacientes sanos y 18 enfermos, con 4 falsos positivos y 7 falsos negativos. Aunque tiene más falsos negativos que Naive Bayes, su mayor ROC-AUC refleja que a nivel global tiene mejor capacidad para separar ambas clases. Es un modelo robusto y equilibrado, adecuado cuando se busca un buen rendimiento general.

5.3.3 Gradient Boosting




Figura 5.3: Matriz de confusión — Gradient Boosting

Gradient Boosting presenta 30 verdaderos negativos y 19 verdaderos positivos, con 6 falsos negativos y 6 falsos positivos. Es el modelo con mayor número de errores totales. Esto confirma que, para este dataset concreto, el aumento de complejidad no se traduce en una mejora real del rendimiento, posiblemente por el tamaño limitado de los datos.

5.3.4 Regresión Logística




Figura 5.4: Matriz de confusión — Regresión Logística

La Regresión Logística obtiene 32 verdaderos negativos, 19 verdaderos positivos, 4 falsos positivos y 6 falsos negativos. Es destacable que un modelo lineal consiga resultados tan competitivos frente a un ensemble de 300 árboles, lo que sugiere que las relaciones entre las variables clínicas y la enfermedad son suficientemente lineales como para que este modelo las capture bien.

5.4 Análisis de interpretabilidad: Shapley Values

Uno de los aspectos más relevantes de este trabajo, y que lo diferencia de los estudios previos sobre este mismo dataset, es el análisis de interpretabilidad de los modelos mediante Shapley Values (SHAP) [9]. Mientras que los trabajos anteriores se limitan a comparar métricas de rendimiento, este análisis permite responder a una pregunta clínicamente esencial: ¿por qué el modelo predice que un paciente tiene enfermedad cardiovascular?

5.4.1 Qué son los Shapley Values

Los Shapley Values son un método procedente de la teoría de juegos que, aplicado al aprendizaje automático, permite medir la contribución de cada variable a una predicción concreta. La idea central es calcular, para cada variable, cuánto cambia la predicción del modelo al incluirla o excluirla, promediando sobre todas las combinaciones posibles de variables. Formalmente, el valor SHAP de la variable j para una predicción concreta se define como:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f(S \cup \{j\}) - f(S)] \quad (5.1)$$

donde F es el conjunto de todas las variables, S es un subconjunto de variables que no incluye j , y $f(S)$ es la predicción del modelo usando solo las variables de S . En la práctica, para modelos basados en árboles se utiliza **TreeExplainer**, que calcula estos

valores de forma exacta y eficiente. Para modelos lineales como la Regresión Logística se utiliza **LinearExplainer**, que aprovecha la estructura lineal del modelo.

Para cada paciente del conjunto de test, SHAP asigna a cada variable un valor numérico: los valores positivos empujan la predicción hacia *enfermo* y los negativos hacia *sano*. De este modo, no solo sabemos si el modelo acierta, sino también qué información ha utilizado para llegar a esa conclusión.

5.4.2 Implementación

El análisis SHAP se ha aplicado a tres de los cuatro modelos entrenados: Random Forest, Gradient Boosting y Regresión Logística. Naive Bayes queda fuera de este análisis debido a que la librería SHAP no dispone de un explainer nativo compatible con modelos probabilísticos gaussianos. La alternativa genérica disponible (KernelExplainer) requiere un coste computacional elevado y produce aproximaciones menos fiables, por lo que se ha considerado fuera del alcance de este trabajo. Para los dos primeros se ha utilizado **TreeExplainer**, el método específico para modelos basados en árboles de decisión. Para la Regresión Logística se ha empleado **LinearExplainer**, diseñado para modelos lineales.

5.4.3 Resultados: importancia media SHAP

La Tabla 5.3 recoge la importancia media SHAP de cada variable para los tres modelos analizados. Este valor se calcula como la media del valor absoluto de los Shapley Values sobre todos los pacientes del conjunto de test, e indica cuánto contribuye de media cada variable a las predicciones del modelo.

Variable	Random Forest	Gradient Boosting	Logistic Reg.
ca	0.1021	1.1125	0.8113
cp	0.1125	0.8928	0.4688
thal	0.0979	0.8690	0.6594
oldpeak	0.0663	0.5167	0.3597
age	0.0361	0.5382	0.0858
thalach	0.0347	0.4226	0.3579
exang	0.0469	0.2967	0.4420
restecg	0.0231	0.3305	0.3541
sex	0.0226	0.3277	0.4148
slope	0.0388	0.2459	0.3312
trestbps	0.0123	0.2333	0.2493

Cuadro 5.3: Importancia media SHAP por variable y modelo (conjunto de test)

Los resultados muestran un patrón consistente entre los tres modelos: las variables *ca* (número de vasos principales afectados), *cp* (tipo de dolor torácico) y *thal* (resultado de la prueba de talasemia) son sistemáticamente las más relevantes para predecir la presencia de enfermedad cardiovascular. Este hallazgo es coherente con el análisis de correlación realizado en el Capítulo 3 y con la evidencia clínica disponible.

En el extremo opuesto, *trestbps* y *restecg* son las variables con menor contribución en todos los modelos. Cabe señalar que los valores absolutos de importancia SHAP difieren considerablemente entre modelos, siendo los de Gradient Boosting notablemente más altos que los de Random Forest. Esto no indica que Gradient Boosting utilice más las variables, sino que cada modelo opera en una escala interna distinta. Lo relevante es el orden de importancia relativa, que es consistente entre los tres modelos.

5.4.4 Gráficos SHAP coloreados por clase predicha

La Figura 5.5 muestra los beeswarm plots de los tres modelos en una sola figura. Cada punto representa un paciente del conjunto de test. La posición horizontal indica el valor SHAP de esa variable para ese paciente, es decir, cuánto ha empujado esa variable la predicción hacia enfermedad (derecha) o hacia sano (izquierda). El color indica la clase que el modelo predijo para ese paciente: rojo si predijo enfermedad, azul si predijo sano.




Figura 5.5: SHAP — Efecto por paciente coloreado por clase predicha (rojo = predicho enfermedad, azul = predicho sano). De izquierda a derecha: Random Forest, Gradient Boosting y Regresión Logística. En los tres modelos, los pacientes predichos como enfermos (rojo) concentran sus puntos a la derecha en variables como *ca* y *cp*, mientras que los predichos como sanos (azul) los concentran a la izquierda, lo que confirma que estas variables son las que más condicionan la predicción en uno u otro sentido.

5.4.5 Coeficientes de la Regresión Logística

La Regresión Logística, a diferencia de los modelos basados en árboles, es directamente interpretable a través de sus coeficientes β_i . Cada coeficiente indica cuánto aumenta o reduce la probabilidad de enfermedad cuando esa variable aumenta una unidad (en escala estandarizada). La Tabla 5.4 muestra los coeficientes obtenidos.

Variable	Coeficiente β
ca	0.8411
thal	0.6721
cp	0.6297
exang	0.4808
sex	0.4182
slope	0.3584
restecg	0.3562
oldpeak	0.3456
trestbps	0.2960
thalach	-0.5122
age	-0.0940

Cuadro 5.4: Coeficientes de la Regresión Logística (variables estandarizadas)

Las variables con coeficiente positivo más alto son *ca*, *thal* y *cp*, lo que indica que valores altos de estas variables aumentan la probabilidad de que el modelo prediga enfermedad. Por el contrario, *thalach* tiene el coeficiente negativo más alto, lo que significa que una frecuencia cardíaca máxima elevada reduce esa probabilidad, resultado coherente con la evidencia clínica.

5.4.6 Comparativa SHAP: predicciones disease vs no disease

Para analizar en qué dirección influye cada variable según la predicción del modelo, se calculó la media y la desviación estándar de los valores SHAP separando los pacientes en dos grupos: los que el modelo predijo como enfermos (*disease*) y los que predijo como sanos (*no disease*). Se muestra esta comparativa para la Regresión Logística al ser el modelo que permite contrastar de forma más directa los valores SHAP con sus coeficientes, ofreciendo así una validación interna de la consistencia del análisis. La columna Diferencia indica qué variables separan más ambos grupos, mientras que la desviación estándar (SD) refleja la dispersión del efecto dentro de cada grupo: una SD alta indica que esa variable no actúa de forma uniforme sobre todos los pacientes del grupo, sino que su efecto varía considerablemente de un paciente a otro. La Tabla 5.5 muestra los resultados.

Variable	Media (disease)	SD (disease)	Media (no disease)	SD (no disease)	Diferencia
ca	1.0500	0.8214	-0.2239	0.3517	1.2739
thal	0.2570	0.5103	-0.5743	0.4826	0.8313
cp	0.2912	0.3841	-0.1966	0.2973	0.4878
exang	0.3165	0.3290	-0.1457	0.2104	0.4622
oldpeak	0.1580	0.3012	-0.2288	0.2641	0.3868
thalach	0.1278	0.2884	-0.2481	0.2356	0.3759
sex	0.1058	0.2317	-0.2153	0.1984	0.3211
slope	0.1221	0.2108	-0.1699	0.1873	0.2921
trestbps	0.1603	0.2241	-0.0856	0.1502	0.2460
restecg	0.1582	0.2193	-0.0292	0.1317	0.1875
age	-0.0506	0.1284	0.0287	0.1096	-0.0793

Cuadro 5.5: SHAP medio y desviación estándar por grupo predicho — Regresión Logística. SD indica la dispersión de los valores SHAP dentro de cada grupo.

Los resultados muestran que *ca* es la variable que más separa ambos grupos, con un SHAP medio de 1.05 en los pacientes predichos como enfermos frente a $-0,22$ en los predichos como sanos (diferencia de 1.27). Su SD en el grupo enfermo (0.82) es también la más alta de la tabla, lo que indica que el número de vasos afectados influye de forma muy desigual entre pacientes: en algunos casos es el factor determinante de la predicción, mientras que en otros su peso es menor. Por el contrario, *restecg* y *age* presentan SDs bajas en ambos grupos, lo que sugiere un efecto más estable y uniforme sobre los pacientes. Le siguen en importancia diferencial *thal* y *cp*, confirmando que estas tres variables son las que más condicionan la decisión del modelo en uno u otro sentido.

5.4.7 Comparativa SHAP vs coeficientes

Una ventaja de la Regresión Logística es que permite comparar directamente sus coeficientes con los valores SHAP. Si ambos apuntan en la misma dirección (positivo o negativo), el modelo es consistente: la variable influye de la misma forma tanto en los pesos aprendidos como en las predicciones individuales. La Tabla 5.6 recoge esta comparativa.

Variable	Coefficiente β	SHAP medio	Misma dirección
age	-0.0940	-0.0012	Sí
sex	0.4182	-0.0942	No
cp	0.6297	-0.0127	No
trestbps	0.2960	0.0071	Sí
restecg	0.3562	0.0414	Sí
thalach	-0.5122	-0.1064	Sí
exang	0.4808	0.0286	Sí
oldpeak	0.3456	-0.0830	No
slope	0.3584	-0.0598	No
ca	0.8411	0.2564	Sí
thal	0.6721	-0.2609	No

Cuadro 5.6: Comparativa SHAP (con signo) vs coeficientes — Regresión Logística

Se observa que las variables *ca*, *age*, *thalach*, *trestbps*, *restecg* y *exang* coinciden en dirección entre coeficiente y SHAP. Sin embargo, variables como *thal*, *cp*, *oldpeak*, *slope* y *sex* presentan diferencias de signo entre ambos análisis. Estas diferencias no deben interpretarse necesariamente como contradicciones: los coeficientes representan el efecto global aprendido por el modelo sobre el conjunto de entrenamiento, mientras que los valores SHAP reflejan la contribución observada en las predicciones concretas del conjunto de test, que puede diferir cuando existen interacciones entre variables o cuando la distribución del test no es perfectamente representativa del entrenamiento. En cualquier caso, las variables más importantes (*ca*, *thalach*) sí coinciden en dirección, lo que refuerza la validez del análisis.

5.5 Comparación y discusión de resultados

Para contextualizar los resultados obtenidos, la Tabla 5.7 compara el rendimiento de los modelos desarrollados en este trabajo con los resultados reportados por estudios previos sobre el mismo dataset.

Trabajo	Modelo	Accuracy	Recall
Perumal y Kaladevi [14]	Regresión Logística	0.87	0.85
Perumal y Kaladevi [14]	SVM	0.85	0.82
Perumal y Kaladevi [14]	KNN	0.69	—
Shrestha [15]	Regresión Logística	0.89	0.91
Shrestha [15]	Random Forest	0.87	0.84
Shrestha [15]	Gradient Boosting	0.85	0.84
Shrestha [15]	XGBoost	0.85	0.84
Shrestha [15]	LSTM	0.85	0.78
Este trabajo	Naive Bayes	0.852	0.800
Este trabajo	Random Forest	0.820	0.720
Este trabajo	Gradient Boosting	0.803	0.760
Este trabajo	Regresión Logística	0.836	0.760

Cuadro 5.7: Comparativa de rendimiento con trabajos previos sobre el mismo dataset

Los resultados obtenidos muestran un patrón interesante: el modelo más sencillo, Naive Bayes, es el que mejor recall obtiene, mientras que el más complejo, Gradient Boosting, es

el que peor rendimiento presenta. Esto sugiere que, para un dataset de tamaño moderado como el utilizado, la complejidad del modelo no garantiza una mejora en los resultados.

En términos de ROC-AUC, Random Forest lidera con 0.900, lo que indica que es el modelo con mejor capacidad discriminativa global. Sin embargo, desde una perspectiva clínica, donde minimizar los falsos negativos es prioritario, Naive Bayes resulta el más adecuado al obtener el recall más alto (0.800) y el menor número de pacientes enfermos clasificados como sanos.

El análisis SHAP añade una dimensión adicional a esta comparación: más allá de los números, permite ver que los tres modelos coinciden en señalar *ca*, *cp* y *thal* como las variables más determinantes. Esta consistencia entre modelos de naturaleza muy diferente refuerza la validez de estos resultados y sugiere que estas variables tienen una relevancia clínica real, no solo una correlación estadística.

Comparando con los trabajos previos, los resultados obtenidos se sitúan en la parte baja del rango reportado en la literatura, que oscila entre el 69 % y el 89 % de accuracy según los trabajos recogidos en la Tabla 5.7. Esto es esperable dado el tamaño limitado del dataset y la ausencia de técnicas avanzadas de optimización de hiperparámetros. Sin embargo, ninguno de esos trabajos incorpora un análisis de interpretabilidad como el realizado aquí, lo que constituye la aportación diferencial de este trabajo.

Cabe señalar que la comparación entre modelos se realiza de forma descriptiva, sin pruebas formales de significación estadística como el test de McNemar o el test de DeLong para ROC-AUC. Dado el tamaño reducido del dataset (303 observaciones), estas pruebas podrían carecer de potencia suficiente para detectar diferencias reales entre modelos. Por ello, su realización queda como línea de trabajo futura; en este trabajo se ha priorizado el análisis interpretativo mediante SHAP, que aporta información más relevante para los objetivos clínicos del estudio dada la muestra disponible. Las diferencias observadas entre modelos deben interpretarse con cautela.

En definitiva, la elección del modelo óptimo depende del objetivo concreto: si se prioriza minimizar los falsos negativos, Naive Bayes es la mejor opción; si se busca la mayor capacidad discriminativa global, Random Forest es más adecuado; y si la interpretabilidad es clave, la Regresión Logística combinada con el análisis SHAP ofrece el mejor equilibrio entre precisión y capacidad de explicación.

5.6 Conclusiones y trabajo futuro

En este trabajo se ha desarrollado un sistema de clasificación para la predicción de enfermedad cardiovascular utilizando diferentes modelos de aprendizaje automático aplicados al dataset Heart Disease Cleveland. A lo largo del análisis se ha podido comprobar cómo, a partir de variables clínicas relativamente sencillas, es posible construir modelos capaces de ofrecer un rendimiento predictivo sólido.

En primer lugar, los resultados muestran que Naive Bayes ha sido el modelo con mejor comportamiento en términos de accuracy y recall. A pesar de ser el más sencillo de los cuatro, es el que menos pacientes enfermos clasifica como sanos, lo que en un contexto clínico es el error más importante a minimizar.

Random Forest y Regresión Logística han ofrecido resultados muy similares entre sí. Random Forest destaca por su ROC-AUC, que indica una mejor capacidad para separar ambas clases en general, mientras que la Regresión Logística resulta especialmente interesante porque es más fácil de interpretar: permite entender directamente qué variables influyen más en la predicción y en qué sentido, algo valioso en un entorno médico.

Gradient Boosting, a pesar de ser el modelo más complejo, ha sido el que peores

resultados ha obtenido. Esto ilustra una lección importante en machine learning: más complejidad no siempre significa mejores resultados, especialmente cuando el dataset es pequeño.

En general, los resultados permiten concluir que modelos sencillos pueden ser muy competitivos en problemas de clasificación médica cuando los datos están bien preparados. También se ha comprobado que usar una sola métrica como el accuracy no es suficiente para evaluar bien un modelo en este tipo de contextos, y que métricas como el recall o el ROC-AUC aportan información mucho más relevante.

El análisis de interpretabilidad mediante Shapley Values constituye la aportación diferencial de este trabajo respecto a estudios previos sobre el mismo dataset. Los resultados SHAP revelan que las variables *ca*, *cp* y *thal* son sistemáticamente las más relevantes en los tres modelos analizados, resultado coherente tanto con el análisis de correlación realizado en la fase exploratoria como con la evidencia clínica disponible. Esta consistencia entre modelos de naturaleza muy diferente refuerza la validez del hallazgo y sugiere que estas variables tienen una relevancia clínica real, más allá de una simple correlación estadística. En un entorno clínico real, este tipo de análisis permitiría a los profesionales sanitarios no solo conocer la predicción del modelo, sino también entender qué factores han llevado a ella, lo que resulta esencial para la toma de decisiones médicas.

Trabajo futuro

Trabajar con más datos.

El dataset utilizado tiene solo 303 pacientes, lo que es un número bastante limitado para entrenar modelos de machine learning. Con más datos, los modelos podrían aprender patrones más generales y obtener mejores resultados, especialmente algoritmos como Gradient Boosting que necesitan más ejemplos para explotar todo su potencial. Una opción concreta sería combinar este dataset con otros similares disponibles públicamente, como los datasets de Cleveland, Hungría y Suiza del repositorio UCI, lo que ampliaría considerablemente el número de observaciones disponibles.

Ajustar mejor los parámetros de los modelos.

En este trabajo se han utilizado configuraciones estándar para cada modelo. Sin embargo, cada algoritmo tiene parámetros que se pueden ajustar para mejorar su rendimiento en un problema concreto. Por ejemplo, en Gradient Boosting se puede variar el número de árboles, la profundidad máxima de cada árbol o la tasa de aprendizaje. Existe una técnica llamada búsqueda en rejilla (*Grid Search*) que prueba automáticamente distintas combinaciones de parámetros y selecciona la que mejor funciona. Aplicarla podría mejorar los resultados obtenidos, especialmente en los modelos ensemble.

Tratar el desbalance entre clases de forma más explícita.

El dataset tiene 164 pacientes sanos y 139 enfermos, un desbalance moderado que puede afectar al rendimiento de los modelos. Existen técnicas específicas para abordar este problema, como SMOTE (*Synthetic Minority Oversampling Technique*), que genera ejemplos sintéticos de la clase minoritaria para equilibrar el dataset. Aplicar estas técnicas podría mejorar especialmente el recall de los modelos, reduciendo el número de pacientes enfermos clasificados como sanos.

Probar modelos más avanzados.

En este trabajo se han analizado cuatro algoritmos clásicos. Existen modelos más recientes que han demostrado un rendimiento superior en problemas similares, como XG-

Boost o LightGBM, que son versiones optimizadas de Gradient Boosting muy utilizadas en la práctica. También sería interesante explorar el uso de redes neuronales, aunque en datasets pequeños como este su ventaja sobre los modelos tradicionales no siempre está garantizada.

Ampliar el análisis de interpretabilidad.

El análisis SHAP realizado en este trabajo se ha aplicado sobre el conjunto de test en su totalidad, obteniendo importancias medias por variable. Una línea de trabajo futura consistiría en profundizar en el análisis a nivel de paciente individual, identificando qué variables han sido determinantes en cada caso concreto. Esto permitiría, por ejemplo, detectar subgrupos de pacientes con perfiles de riesgo distintos o validar los resultados con criterio clínico experto.

En definitiva, este trabajo pone de manifiesto el potencial del aprendizaje automático como herramienta de apoyo en el análisis de datos clínicos. Los resultados obtenidos son prometedores y abren la puerta a desarrollos futuros que podrían contribuir a la detección temprana de enfermedades cardiovasculares y, en última instancia, a mejorar la atención a los pacientes.

Bibliografía

- [1] World Health Organization. Cardiovascular diseases (cvds), 2023.
- [2] Gregory A. Roth, George A. Mensah, et al. Global burden of cardiovascular diseases and risk factors, 1990–2019. *Journal of the American College of Cardiology*, 76(25):2982–3021, 2020.
- [3] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436–444, 2015.
- [4] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [5] Ziad Obermeyer and Ezekiel J. Emanuel. Predicting the future — big data, machine learning, and clinical medicine. *New England Journal of Medicine*, 375(13):1216–1219, 2016.
- [6] Cynthia Rudin. Stop explaining black box models. *Nature Machine Intelligence*, 2019.
- [7] Erico Tjoa and Cuntai Guan. A survey on explainable artificial intelligence (xai): Toward medical xai. *IEEE Transactions on Neural Networks and Learning Systems*, 32(11):4793–4813, 2021.
- [8] UCI Machine Learning Repository. Heart disease dataset, 2019.
- [9] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, 2017.
- [10] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. MIT Press, 2012.
- [11] David W. Hosmer. *Applied Logistic Regression*. Wiley, 2013.
- [12] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [13] Jerome Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29:1189–1232, 2001.
- [14] Ramya Perumal and A. C. Kaladevi. Early prediction of coronary heart disease from cleveland dataset using machine learning techniques. *International Journal of Advanced Science and Technology*, 29(06):4225–4234, 2020.
- [15] Ashish Shrestha. Heart disease prediction using machine learning algorithms. *International Journal of Computer Applications*, 2024.
- [16] N. Chandrasekhar and S. Peddakrishna. Enhancing heart disease prediction accuracy through machine learning techniques and optimization. *Processes*, 11(4):1210, 2023.
- [17] Andras Janosi, William Steinbrunn, Matthias Pfisterer, and Robert Detrano. Heart disease dataset. *UCI Machine Learning Repository*, 1988.

Anexo: Resultados adicionales

Validación de la implementación manual de Naive Bayes

Como parte del trabajo, se implementó el algoritmo Naive Bayes desde cero, calculando manualmente las probabilidades a priori y condicionales. Al comparar los resultados de esta implementación con los de la versión de scikit-learn, ambas obtienen exactamente el mismo accuracy: 85.25 %. Esto confirma que el desarrollo manual es correcto y que los cálculos se realizan de forma adecuada, lo que ayuda a entender mejor el funcionamiento interno del algoritmo más allá de usar una librería como una caja negra.

Consistencia de los resultados

Un aspecto relevante es la consistencia entre los resultados de la validación cruzada y los del conjunto de prueba. En ambos casos Naive Bayes lidera en accuracy y recall, y Regresión Logística obtiene resultados muy cercanos, lo que confirma que este patrón no depende de una partición concreta de los datos. La diferencia entre la accuracy media de la validación cruzada y la del conjunto de prueba es pequeña en todos los casos, lo que sugiere que los modelos generalizan bien y no están sobreajustados.